Repetisjon

IN1160 – seminar – uke 8

Vår 2026

Oppgave: kNN

Du er gitt et todimensjonalt datasett med to klasser og to umerkede punkter.
Beregn den euklidske avstanden fra hvert umerket punkt til de nærmeste merkede punktene, og identifiser de k nærmeste naboene.
Tildel en klasse ved hjelp av flertallsavstemning for k=1,3,5.
Endrer den predikerte klassen seg når k endres? Hva forteller dette om stabiliteten til metoden?

Euklidsk avstand

$$d(a,b) = \sqrt{\sum_{i=1}^{n} (a_i - b_i)^2}$$

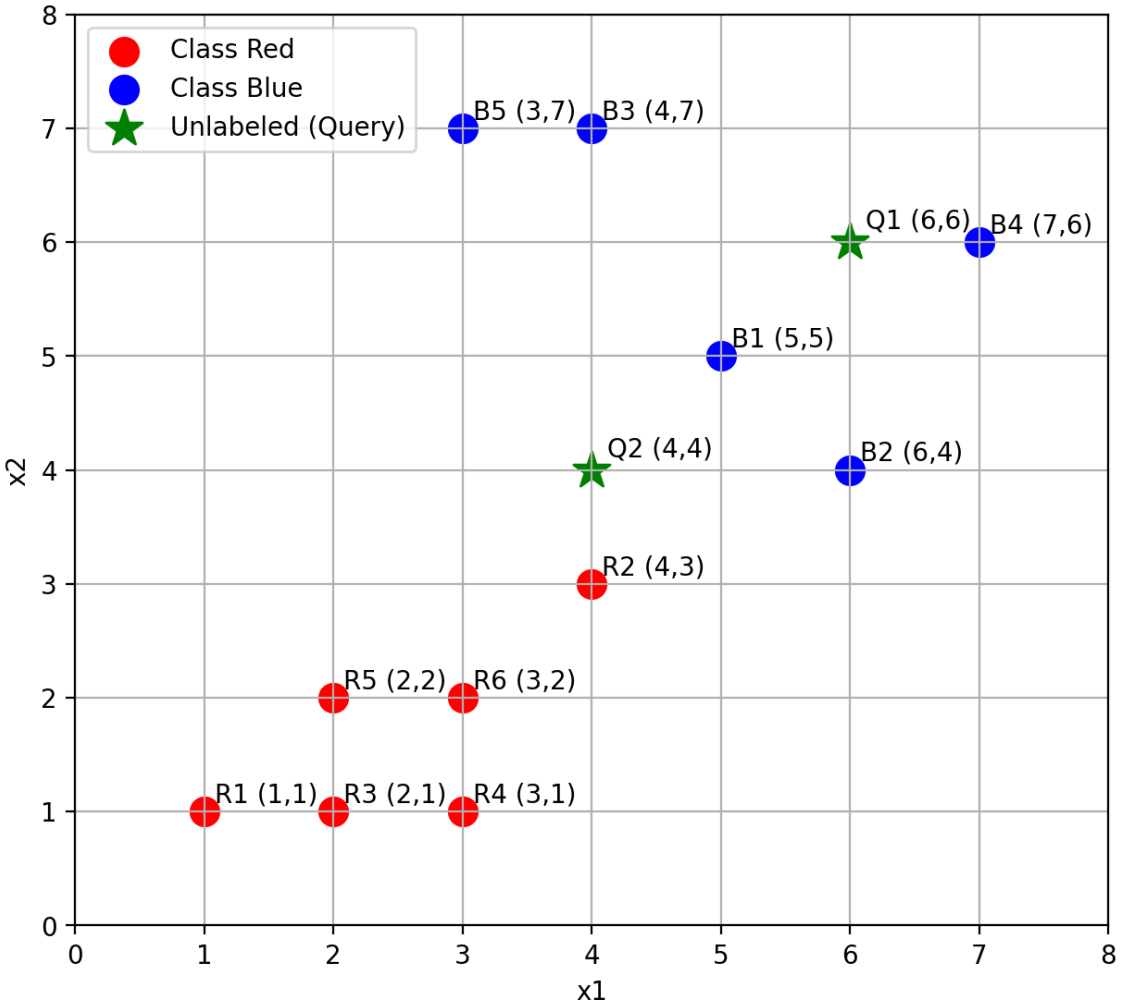

Oppgave: Linearitet

- I figuren er input plottet langs x- aksen mot de sanne verdiene i y-aksen. I hvilke av plottene virker det rimelig å anta lineær sammenheng mellom input og de sanne verdiene? I tilfellene som ikke er lineære, hvordan type sammenheng er det mellom inputet og de sanne verdiene?

- Hva kan skje om man bruker lineær regresjon på data som er tydelig ikke-lineær?

- Finnes det noen triks for fortsatt å kunne bruke lineær regresjon i settinger som ikke er lineære?

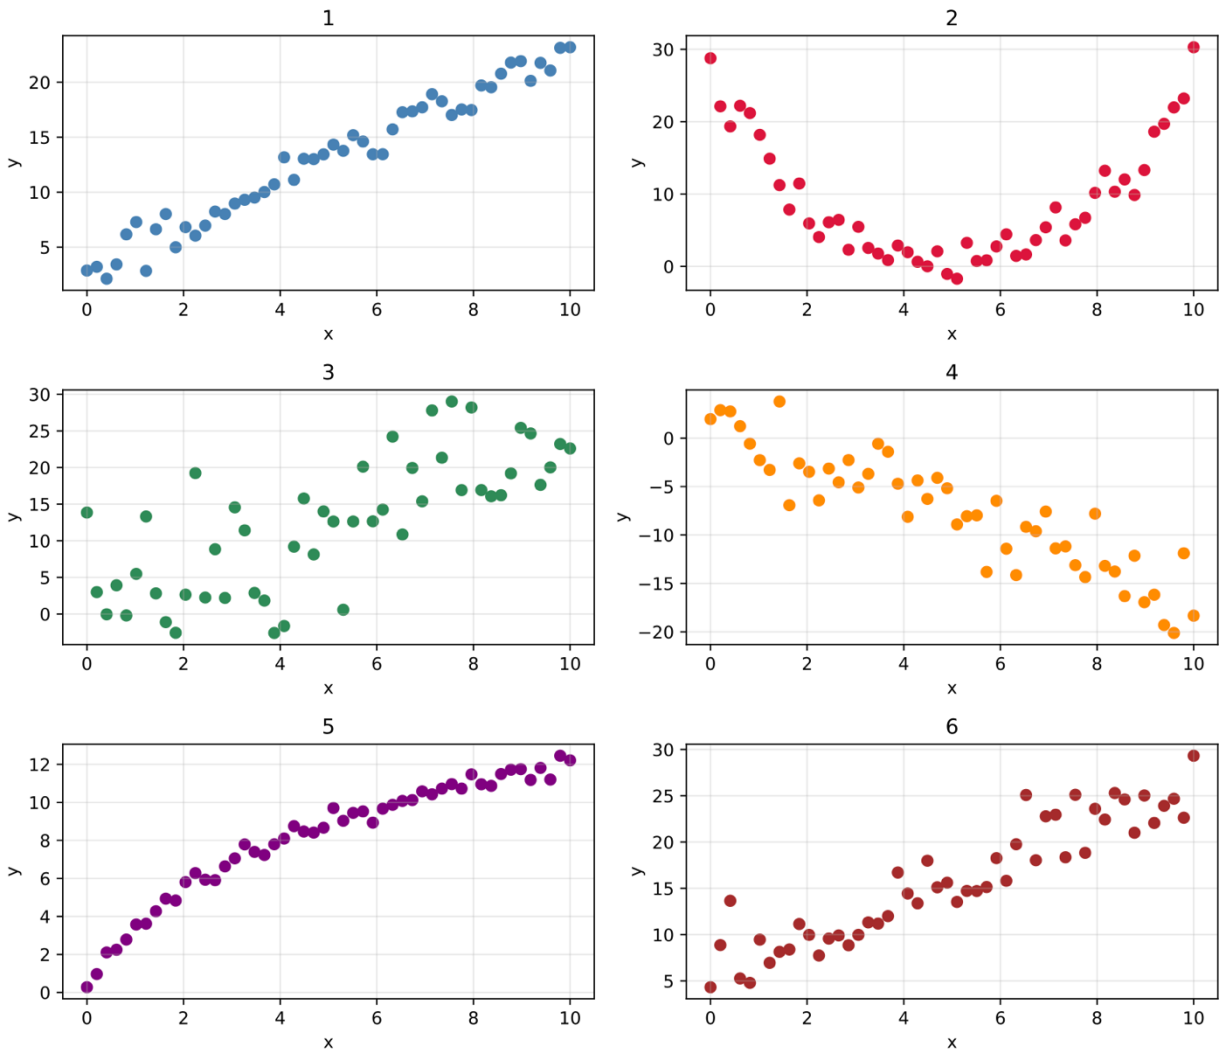

Lineær regresjon: Prediksjon

En modell tar to inputs, x1 og x2.
Koeffisientene til disse inputene er henholdsvis 3 og –2, og konstantleddet er 1.5.

Gitt følgende input, hva blir prediksjonen?

a) $\mathbf{x}_1 = (x_{1,1}, x_{1,2}) = (1, 2)$

b) $\mathbf{x}_2 = (x_{2,1}, x_{2,2}) = (1.5, -1)$

c) $\mathbf{x}_3 = (x_{3,1}, x_{3,2}) = (0, 10)$

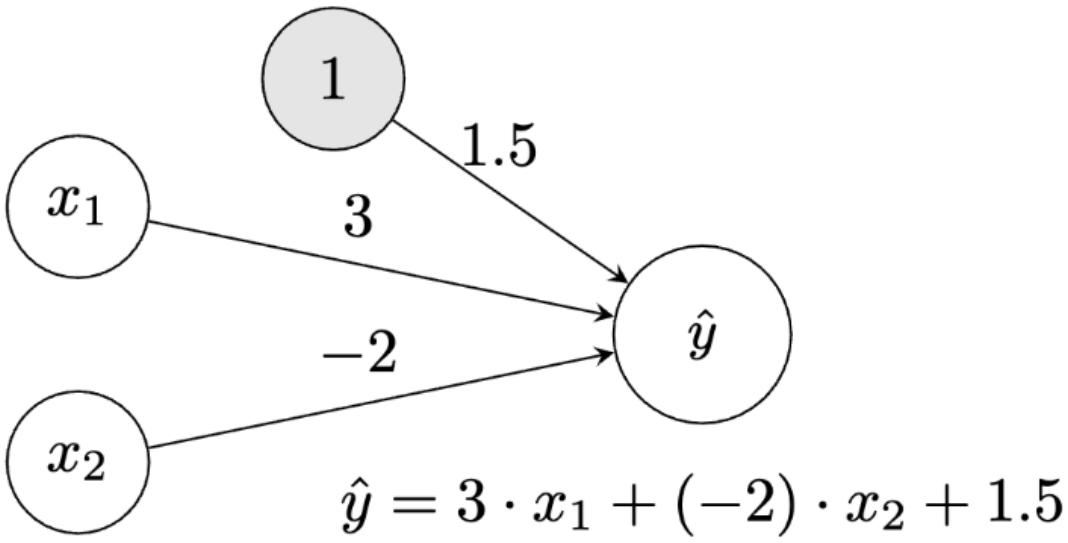

$$\hat{y} = 3 \cdot x_1 + (-2) \cdot x_2 + 1.5$$

Figur 2: Eksempel på en spesifikk lineær regresjonsmodell.

Lineær regresjon: Tapsfunksjon

Beregn nå *gjennomsnittlig kvadratfeil*, også kalt *mean squared error* (MSE).

MSE er definert ved formelen.

Gitt de sanne y-verdiene y = (y1, y2, y3) = (-0.5, 10, -20.5) for henholdsvis a), b) og c) prediksjonene fra før, hva blir MSE'en?

$$\mathrm{MSE}(\mathbf{y}, \hat{\mathbf{y}}) = \frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

Lineær regresjon: Koeffisient-oppdatering

Vi kan nå bruke prediksjonene og de sanne verdiene til å oppdatere koeffisientene med *gradientnedstigning*. Vi ønsker nå å finne koeffisientene som minimerer MSE. Den deriverte til MSE-en med hensyn til en av koeffisientene (β_j) gir et tall som forteller oss hvor mye MSE-en vil vokse dersom vi gjør en liten endring i β_j. Gjøres dette for alle koeffisientene, får vi *gradienten*.

Gradienten forteller hvilken retning MSE øker mest. Derfor må vi oppdatere koeffisientene i motsatt retning (negativ gradient). Vi tar små steg (bestemt av læringsraten, η) for å unngå å hoppe forbi minimum.

Hver koeffisient må nå oppdateres til steg nummer k, hvor de tidligere koeffisientene er fra steg k-1. Vi bruker derivasjonsregler og fyller inn i oppdateringsregelen for lineær regresjon (selve utregningen er ikke del av pensum) og får uttrykkene til høyre. n er antall datapunkter.

La η være 0.03 og bruk prediksjonene $\hat{y}_1$, $\hat{y}_2$, og $\hat{y}_3$ fra før. Regn ut:

a) Den nye verdien til β_0

b) Den nye verdien til β_1

c) Den nye verdien til β_2

$$\nabla_\beta \mathrm{MSE}(\mathbf{y}, \hat{\mathbf{y}}) = \left(\frac{\partial \mathrm{MSE}(\mathbf{y}, \hat{\mathbf{y}})}{\partial \beta_0}, \frac{\partial \mathrm{MSE}(\mathbf{y}, \hat{\mathbf{y}})}{\partial \beta_1}, \frac{\partial \mathrm{MSE}(\mathbf{y}, \hat{\mathbf{y}})}{\partial \beta_2} \right)$$

Koeffisient-oppdateringer

$$\beta_0^{(k)} \leftarrow \beta_0^{(k-1)} - \eta \frac{1}{n} \sum_{i=1}^{n} (\hat{y}_i - y_i)$$

$$\beta_1^{(k)} \leftarrow \beta_1^{(k-1)} - \eta \frac{1}{n} \sum_{i=1}^{n} (\hat{y}_i - y_i) x_{i,1}$$

$$\beta_2^{(k)} \leftarrow \beta_2^{(k-1)} - \eta \frac{1}{n} \sum_{i=1}^{n} (\hat{y}_i - y_i) x_{i,2}$$

Input

$$\mathbf{x}_1 = (x_{1,1}, x_{1,2}) = (1, 2)$$

$$\mathbf{x}_2 = (x_{2,1}, x_{2,2}) = (1.5, -1)$$

$$\mathbf{x}_3 = (x_{3,1}, x_{3,2}) = (0, 10)$$

Lineær regresjon: Nye prediksjoner

Med de nye vektene kan vi regne ut prediksjonene på nytt og se om vi får bedre resultat. Vi kan også bruke dette til å regne ut nye vekter en gang til, og så videre.

a) Regn ut prediksjonene for datapunktene (1, 2), (1.5, −1) og (0, 10) fra oppgave før ved å bruke de nye vektene du nettopp beregnet.
b) Regn ut MSE-en (gitt de samme sanne verdiene y = (−0.5, 10, −20.5) som før) med de nye prediksjonene. Hvordan ble resultatet sammenliknet med MSE-en med de forrige vektene? Hvorfor tror du det ble slik?

Nevrale nettverk regneoppgave: Forover-fasen

Vi har et lite nevralt nettverk som består av to inndata trekk, ett skjult lag med to nevroner og ett utgangsnevron. Det skjulte laget bruker **ReLU**-aktiveringsfunksjonen, mens utgangslaget bruker **sigmoid**-aktiveringsfunksjonen.

Vi er gitt en inputvektor x = (x1, x2) = (1,2)

1) Basert på vekter og konstantledd vist på figuren, bestem ligningen for z_2
2) Beregn pre-aktiveringsverdiene, z_1 og z_2, for det skjulte laget
3) Bruk deretter ReLU-funksjonen for å finne utgangene h_1 og h_2 fra det skjulte laget
4) Basert på vekter og konstantledd vist på figuren, bestem ligningen for z_{out}
5) Beregn nå pre-aktiveringsverdien z_{out} for output-nevronet
6) Bruk sigmoid-funksjonen for å få den predikerte verdien ŷ
7) Til slutt, klassifiser inputen som klasse 1 hvis ŷ > 0.5, ellers som klasse 0.

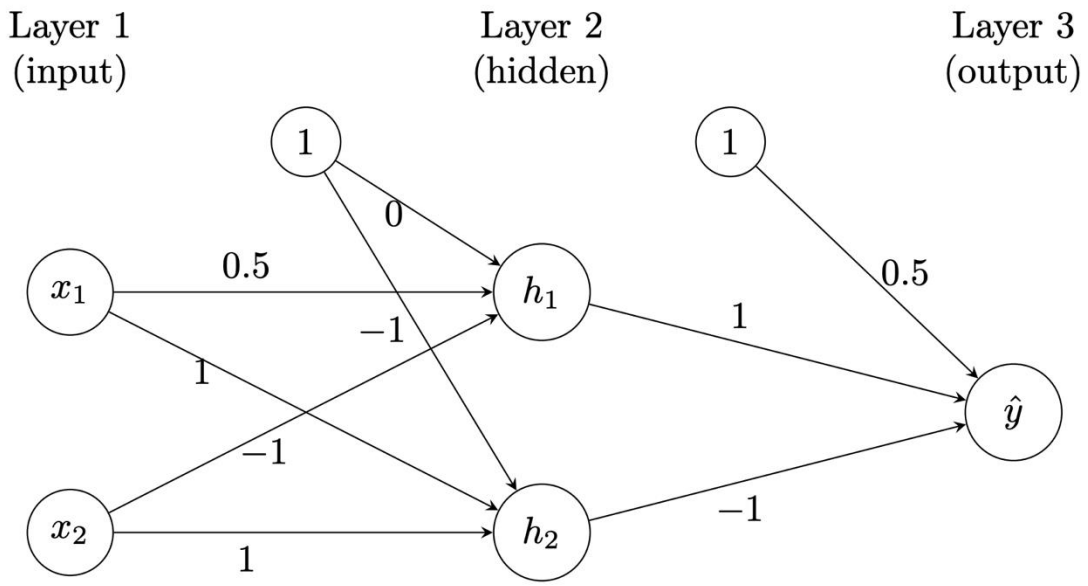

$$z_1 = 0.5\,x_1 - 1\,x_2 + 0$$

$$z_2 = \quad ?$$

$$z_{out} = \quad ?$$

Aktiveringsfunksjoner

$$\mathrm{ReLU}(z) = \max(0, z)$$

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Oppgave: Klassifikasjonsgrenser

Du ser tre spredningsplott med to variabler og to klasser. Forestill deg at du skal bygge en modell som skal klassifisere punktene, og at du ønsker å tegne en linje som skiller punktene som tilhører de to klassene. Reflekter og tegn klassifikasjonsgrenser for tre ulike scenarier:

- Undertilpasning – En svært enkel grense som ikke fanger opp viktige mønstre i dataene.
- God tilpasning – En grense som ser ut til å skille klassene godt.
- Overtilpasning – En svært kompleks grense som tilpasser seg støy i dataene.

Hva betyr det at en modell er kompleks?
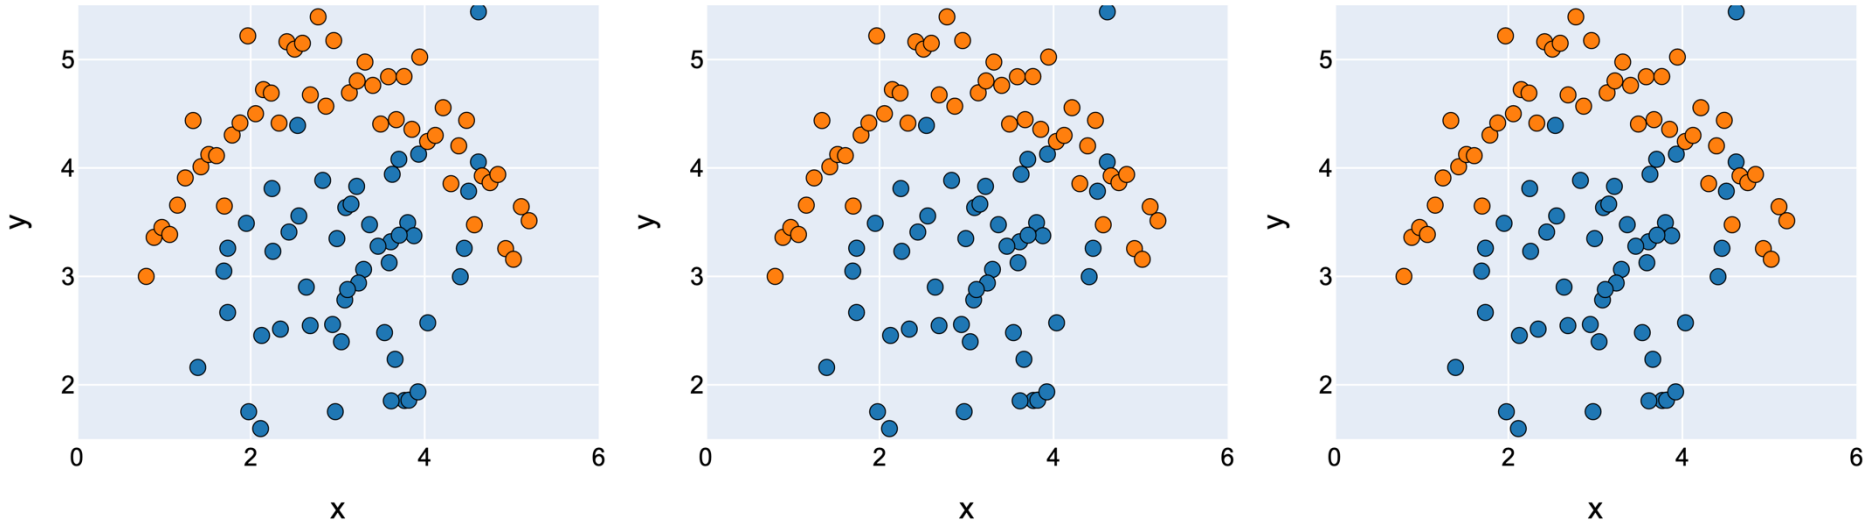
Hvordan påvirker denne kompleksiteten hvor godt modellen fanger opp strukturen i dataene?