Beslutningstrær og ensemble-metoder

IN1160 – seminar – uke 8

Vår 2026

Refleksjon og diskusjon

Tenk først individuelt og diskuter deretter sammen i grupper (2-3 studenter):

- Hva er et beslutningstre?
- Hva er rollen til en node, en kant og en løvnode i et beslutningstre?
- Hvordan lager det prediksjoner?
- Hva er et deltre (subtree) og en beslutningsstubbe (decision stump)?
- Basert på treet fra figuren, lag en prediksjon om noen foretar et kjøp, gitt at de tjener 55 000, er 35 år gamle, og aldri har foretatt et kjøp i den butikken før.
- Tenk deg at du designer en modell for å bestemme om noen får et lån eller ikke. Hva slags spørsmål kan modellen din stille om søkeren?

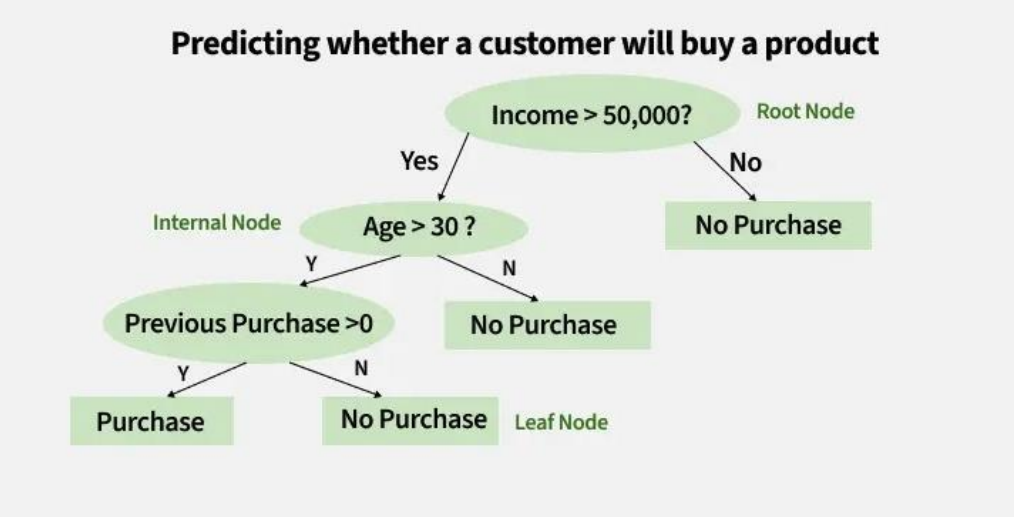

Oppgave: Bygg et beslutningstre

Scenario: Du trener en lånegodkjenningsklassifikator på et lite sett med 30 treningsobservasjoner.

Målet er å bestemme om søkerens lånesøknad blir innvilget. De 30 observasjonene er oppsummert til høyre.

Har stabil jobb?	Har ubetalt gjeld?	Lån godkjent	Antall observasjoner
Ja	Nei	Ja	10
Ja	Ja	Nei	5
Nei	Nei	Nei	8
Nei	Nei	Ja	1
Nei	Ja	Nei	6

I grupper:

1) Identifiser de to binære inndatatrekk og variabelen vi ønsker å bestemme
2) Lag to beslutningsstubber fra de to binære trekk
3) Beregn for hver stubbe:
   - Hvor mange observasjoner som er riktig klassifisert (ved å bruke majoritetsklassen i hver kant)
   - Den totale nøyaktigheten til hver stubbe
4) Bygg det fulle beslutningstreet ved å splitte på begge trekk. Velg beslutningsstubben med høyest nøyaktighet som roten i treet. Del deretter dataene basert på det andre trekk hvis delingen forbedrer nøyaktigheten for noden.

Løsning

Stubbe 1 (Har stabil jobb?)
Nøyaktighet = 24/30 = 80%

Stubbe 2 (Har ubetalt gjeld?)
Nøyaktighet = 22/30 ≈ 73.3%

Stubbe 1 velges som roten

Oppgave: Bygg et beslutningstre

Scenario fortsatt: Beregning av evalueringsmål og tegning av beslutningsgrenser

1) Hva er nøyaktigheten til modellen (fullt tre) på treningsdataene?
2) Hva er verdiene for presisjon (precision) og sensitivitet (recall) for å forutsi at et lån blir godkjent?
3) Hva betyr det å beskjære treet (pruning)?
4) Hvordan ville verdiene for nøyaktighet, presisjon og sensitivitet endre seg hvis du beskar treet etter den første stubbe (bare nødvendig på en side)?
5) Å beskjære treet kan ikke forbedre nøyaktigheten til disse 30 treningsobservasjonene. Kan dere likevel tenke dere situasjoner der beskjæring ville vært en nyttig teknikk? Hva tror dere ville skjedd med nøyaktigheten på *nye*, usette observasjoner?
6) Skisser et plott som viser punktene og beslutningsgrensen(e) for beslutningstre-modellen (uten beskjæring).

Har stabil jobb?	Har ubetalt gjeld?	Lån godkjent	Antall observasjoner
Ja	Nei	Ja	10
Ja	Ja	Nei	5
Nei	Nei	Nei	8
Nei	Nei	Ja	1
Nei	Ja	Nei	6

Løsning

Fullt tre:
Nøyaktighet = 29/30 ≈ 96.7%
Presisjon = 10/10 = 100%
Sensitivitet = 10/11 ≈ 90.9%

Beskjært tre:
Nøyaktighet = 24/30 = 80%
Presisjon = 10/15 ≈ 66.7%
Sensitivitet = 10/11 ≈ 90.9%

Oppgave: Bygg et beslutningstre

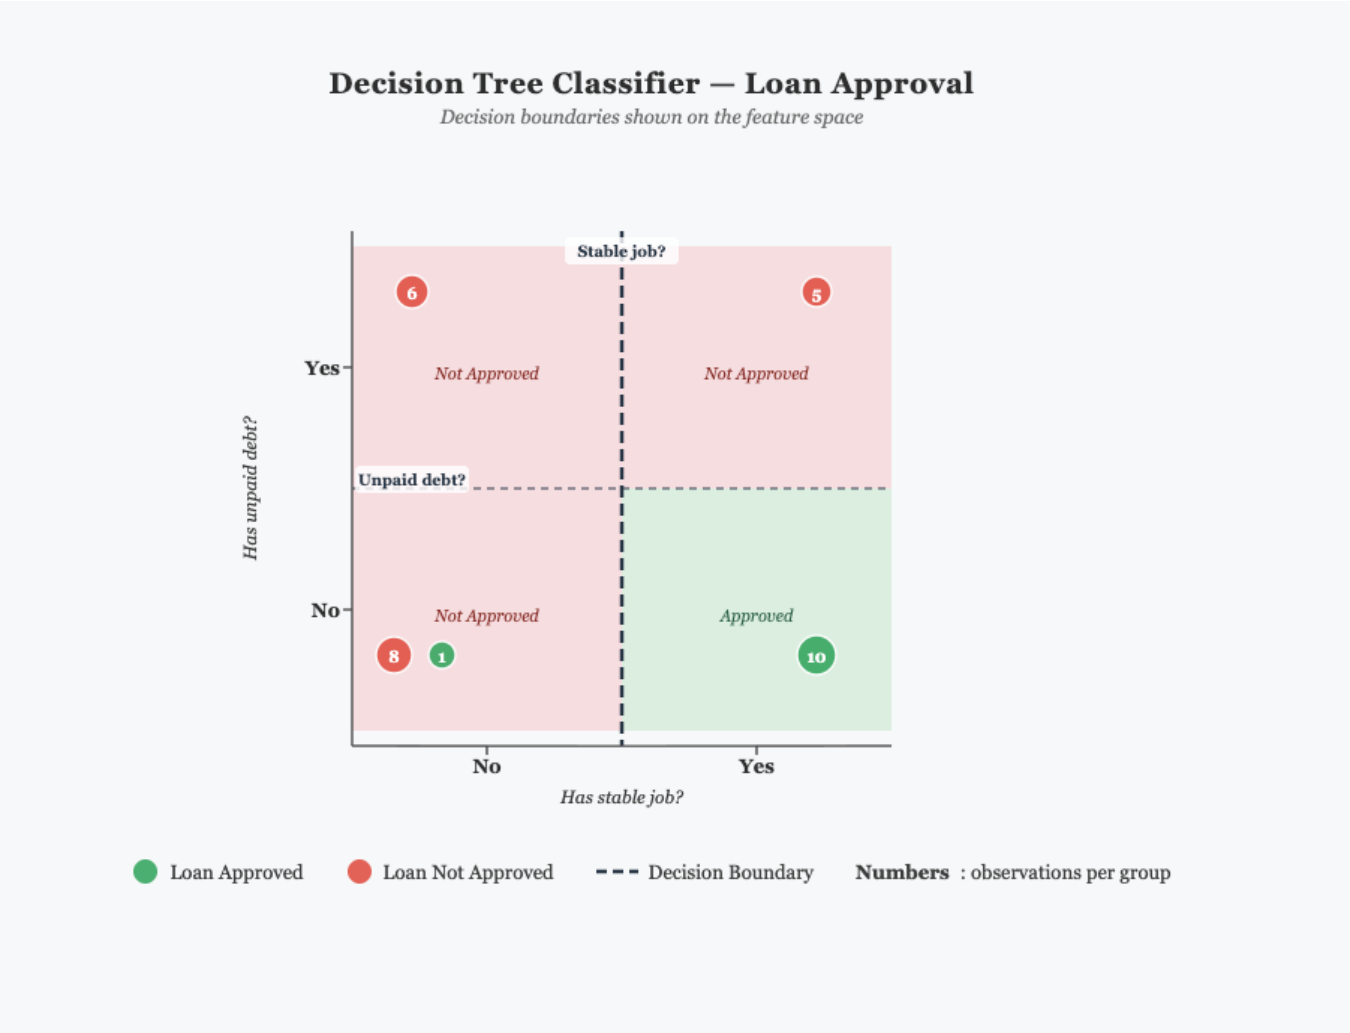

Repetisjon fra forelesningen: Entropi

Entropi kan brukes til å velge den beste delingen i et beslutningstre.

Entropien måler renheten av nodene.

- Lav entropi = rene noder og lav usikkerhet (eksempel: entropi 0 betyr helt rene noder)
- Høy entropi = urene noder og høy usikkerhet (eksempel: entropi 1 betyr helt urene noder)

Informasjonsgevinsten: mål for reduksjonen i entropi etter dataene splittes (altså hvor mye usikkerheten blir redusert av splitten)

- Høy IG = god splitt
- Lav IG = dårlig splitt

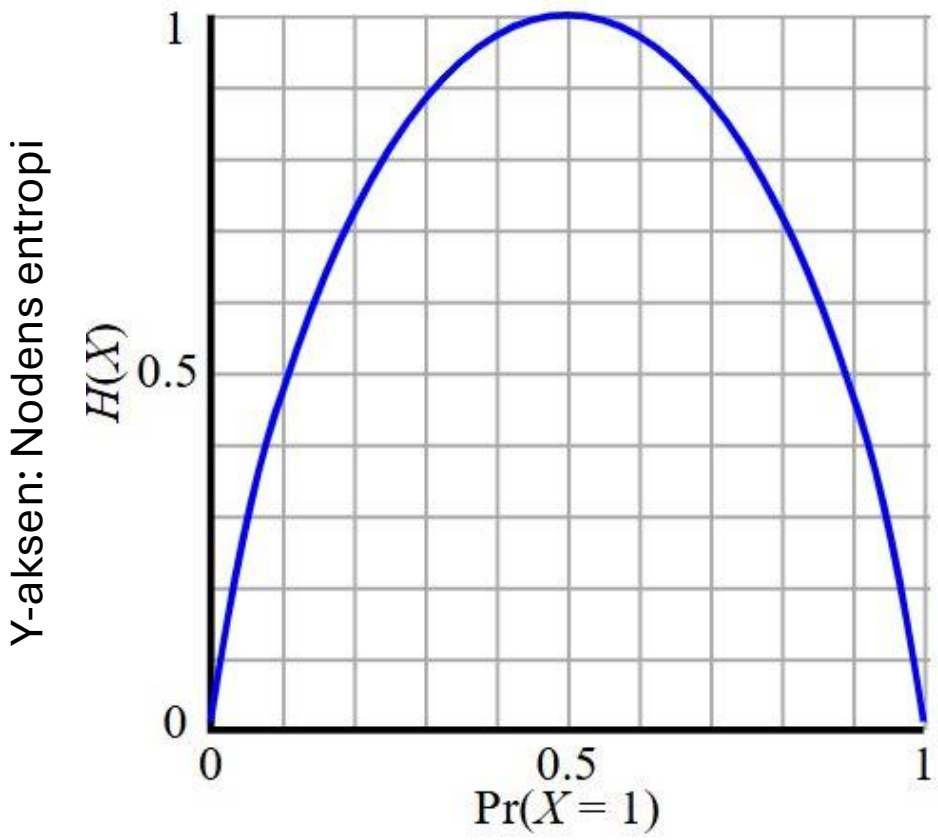

X-aksen: Andel av datapunkter i noden som tilhører klasse 1

Diskusjon: Entropi

Entropi kan brukes til å velge den beste delingen i et beslutningstre.

Diskuter i grupper:

1) Hva betyr det at en node er ren eller uren?
2) Hvorfor er ikke alltid nøyaktighet den beste måten å velge en splitting på? (Vanskelig bonusspørsmål)
3) Hvordan kan vi måle hvor "blandet" klassene er i en node?
4) Hvordan brukes entropi når man skal bestemme hvor man skal splitte?

Entropi

$$H(t) = -\sum_k p_k \log_2(p_k)$$

Hvor p_k er proporsjonen av observasjoner i node t som tilhører klasse k.

Informasjonsgevinst ved å splitte på trekk *f*

$$\mathrm{IG}(t, f) = H(t) - \sum_{\text{branches}} \frac{n_{\text{branch}}}{n} H(\text{branch})$$

hvor H(t) er entropien til den foreldrenoden, n_{branch} er antall observasjoner i hver kant, og *n* er det totale antallet observasjoner i foreldrenoden.

Beregning: Entropi

Har stabil jobb?	Har ubetalt gjeld?	Lån godkjent	Antall observasjoner
Ja	Nei	Ja	10
Ja	Ja	Nei	5
Nei	Nei	Nei	8
Nei	Nei	Ja	1
Nei	Ja	Nei	6

Ved å bruke det samme datasettet som før, beregn og diskuter i grupper:

1) Beregn entropien til datasettet før splitting.
2) Beregn entropien til hver kant etter splitting på hver trekk, og beregn informasjonsgevinsten for hver splitting.
3) Diskuter hvilket trekk som gir den største informasjonsgevinst og som ville bli valgt som den beste splitting. Bygg det fulle beslutningstreet ved å velge den beste splitten som roten og deretter splitte dataene basert på det andre trekk hvis delingen forbedrer entropien. Ser det resulterende treet likt ut som i den forrige oppgaven (der splittingen ble gjort basert på nøyaktighet)?
4) Er en nodes entropi generelt lavere enn entropien til foreldrenoden? Er den generelt lavere/større, eller alltid lavere/større? (Vanskelig bonusspørsmål)

Entropi

$$H(t) = -\sum_k p_k \log_2(p_k)$$

Hvor p_k er proporsjonen av observasjoner i node t som tilhører klasse k.

Informasjonsgevinst ved å splitte på trekk *f*

$$\mathrm{IG}(t, f) = H(t) - \sum_{\text{branches}} \frac{n_{\text{branch}}}{n} H(\text{branch})$$

hvor H(t) er entropien til den foreldrenoden, n_{branch} er antall observasjoner i hver kant, og n er det totale antallet observasjoner i foreldrenoden.

Beregning: Entropi

Har stabil jobb?	Har ubetalt gjeld?	Lån godkjent	Antall observasjoner
Ja	Nei	Ja	10
Ja	Ja	Nei	5
Nei	Nei	Nei	8
Nei	Nei	Ja	1
Nei	Ja	Nei	6

- Entropi før splitting:

$$H(\text{root}) = -\frac{11}{30}\log_2\left(\frac{11}{30}\right) - \frac{19}{30}\log_2\left(\frac{19}{30}\right) \approx 0.948 \text{ bits}$$

- Entropi og informasjonsgevinst etter splitting på "Har stabil jobb?"

$$H(\text{Yes}) = -\frac{10}{15}\log_2\left(\frac{10}{15}\right) - \frac{5}{15}\log_2\left(\frac{5}{15}\right) \approx 0.918 \text{ bits} \quad H(\text{No}) = -\frac{1}{15}\log_2\left(\frac{1}{15}\right) - \frac{14}{15}\log_2\left(\frac{14}{15}\right) \approx 0.353 \text{ bits}$$

$$H_{\text{after}} = \frac{15}{30}\cdot 0.353 + \frac{15}{30}\cdot 0.918 \approx 0.636 \text{ bits} \quad \text{IG}(\textit{stable job}) = 0.948 - 0.636 \approx \mathbf{0.312 \text{ bits}}$$

- Entropi og informasjonsgevinst etter splitting på "Har ubetalte gjeld?"

$$H(\text{Yes}) = 0 \quad H(\text{No}) = -\frac{11}{19}\log_2\left(\frac{11}{19}\right) - \frac{8}{19}\log_2\left(\frac{8}{19}\right) \approx 0.981 \text{ bits}$$

$$H_{\text{after}} = \frac{19}{30}\cdot 0.981 + \frac{11}{30}\cdot 0 \approx 0.621 \text{ bits} \quad \text{IG}(\textit{unpaid debt}) = 0.948 - 0.621 \approx \mathbf{0.327 \text{ bits}}$$

Entropi

$$H(t) = -\sum_k p_k \log_2(p_k)$$

Hvor p_k er proporsjonen av observasjoner i node t som tilhører klasse k.

Informasjonsgevinst ved å splitte på trekk *f*

$$\text{IG}(t, f) = H(t) - \sum_{\text{branches}} \frac{n_{\text{branch}}}{n} H(\text{branch})$$

hvor H(t) er entropien til den foreldrenoden, n_{branch} er antall observasjoner i hver kant, og *n* er det totale antallet observasjoner i foreldrenoden.

Beregning: Entropi

Har stabil jobb?	Har ubetalt gjeld?	Lån godkjent	Antall observasjoner
Ja	Nei	Ja	10
Ja	Ja	Nei	5
Nei	Nei	Nei	8
Nei	Nei	Ja	1
Nei	Ja	Nei	6

- Splitt på 'Har ubetalt gjeld?' gir høyere informasjonsgevinst.

$$\mathrm{IG}(\textit{unpaid debt}) \approx 0.327 \quad > \quad \mathrm{IG}(\textit{stable job}) \approx 0.312$$

- Kanten *Har ubetalt gjeld?* = *Ja* er ren, men kanten *Har ubetalt gjeld?* = *Nei* er fortsatt uren. Vi må derfor sjekke om en videre splitt på den gjenværende variabelen, *Har stabil jobb?*, reduserer entropien.

$$H(\text{debt} = \text{No}) = -\frac{11}{19}\log_2\left(\frac{11}{19}\right) - \frac{8}{19}\log_2\left(\frac{8}{19}\right) \approx 0.981 \quad H(\text{No}) = -\frac{1}{9}\log_2\left(\frac{1}{9}\right) - \frac{8}{9}\log_2\left(\frac{8}{9}\right) \approx 0.503$$

$$H(\text{Yes}) = 0 \qquad H_{\text{after}} = \frac{10}{19}\cdot 0 + \frac{9}{19}\cdot 0.503 \approx 0.238 \qquad 0.238 < 0.981$$

- Vi legger til en ny splitt på *'Har stabil jobb?'*.

Entropi

$$H(t) = -\sum_k p_k \log_2(p_k)$$

Hvor p_k er proporsjonen av observasjoner i node t som tilhører klasse k.

Informasjonsgevinst ved å splitte på trekk *f*

$$\mathrm{IG}(t, f) = H(t) - \sum_{\text{branches}} \frac{n_{\text{branch}}}{n} H(\text{branch})$$

hvor H(t) er entropien til den foreldrenoden, n_{branch} er antall observasjoner i hver kant, og *n* er det totale antallet observasjoner i foreldrenoden.

Diskusjon: Beslutningstrær

Reflekter individuelt (~2 min) og diskuter deretter sammen i grupper (~10 min):

1) Hva er styrkene og begrensningene til beslutningstrær?
2) Hvordan skiller et beslutningstre seg fra nevrale nettverk når det gjelder forklarbarhet?
3) Hvis et beslutningstre modellerer mønstre som ikke generaliserer til nye, usette data (overtilpasning), hva kan vi gjøre for å regulere det?

Ensemblemetoder

Reflekter individuelt (~2 min) og diskuter deretter sammen I grupper (~10 min):

1) Hva mener vi med ensemblemetoder i maskinlæring, og hvordan forholder dette seg til ideen om "Wisdom of Crowds"?
2) Det er velkjent at mange trær er bedre enn ett, så lenge de er forskjellige nok. Hva betyr det at trærne er forskjellige? Hvorfor må de være forskjellige? Hva kan vi gjøre for å sikre variasjon mellom trærne?
3) Se for deg at du trente fem modeller på nøyaktig de samme treningsdataene, og at de alle oppnådde 95% presisjon, men å kombinere dem forbedret ikke resultatene. Hvorfor kan det være slik?
4) Hva er forskjellen mellom myke og harde avstemmingsklassifikatorer?

"Wisdom of Crowds" i praksis

Spørsmål: Hvilket land i Europa spiste flest kilo pizza per innbygger i 2024?

- Sverige
- Norge
- Italia
- Sveits

Individuelt: Skriv ned hvor sikkert hvert av svarene er (de må summere seg til 100 %). For eksempel: Sverige 10 %, Norge 20 %, Italia 20 % og Sveits 50 %.

I gruppen: Del resultatene deres og prøv å velge et svar basert på soft voting (gjennomsnitt over sikkerheter) og hard voting (flertallsavstemning).