Generativ KI

IN1160 - Seminar

Vår 2026

Hjernetømming

Individuelt (~4 min)

På papir (eller datamaskinen din), skriv ned alt du tenker på, når du hører begrepet **generativ KI**. Skriv så mange ord, uttrykk eller ideer som mulig.

I grupper på 3-4 (~6 min)

Del ideene deres. Som gruppe bør dere:

- Identifisere vanlige ideer eller temaer som dukker opp i flere lister,
- Fremheve unike eller overraskende ideer som ikke dukket opp ofte, og forklare hvorfor dere kom på dem,
- Bli enige om 3–5 hovedideer som best beskriver hva generativ KI betyr for gruppen deres.

Grupper deler ideene sine med klassen.

Generell Diskusjon om Generativ KI

Reflekter først individuelt (~3 min), og diskuter deretter i grupper (~10 min):

1) Hvilke typer generative KI-verktøy eller -applikasjoner bruker du? I hvilke oppgaver eller situasjoner synes du de er nyttige?
2) Hva er det som generativ KI fortsatt ikke kan gjøre bra, eller ikke kan gjøre for deg?
3) Ville du anse generativ KI som mer lik veiledet eller uveiledet læring? Hvorfor?
4) Hva betyr det at generative modeller lærer den underliggende fordelingen av dataene? Og hvordan hjelper det med å generere nye datapunkter?

Generativ KI i ulike fagfelt

Gruppearbeid og utforsking (~20 min)

Hver gruppe får tildelt et fagfelt (f.eks. utdanning, helse, biologi, kunst, media, teknologi, næringsliv, jus).

Diskuter og tenk gjennom (og gjør gjerne et kort nettsøk) følgende:

1) Hvordan brukes generativ KI i dette fagfeltet i dag?
2) Hvilke mulige fremtidige bruksområder finnes i dette fagfelt?

Presentasjoner (~10 min)

Hver gruppe presenterer kort hva de har funnet.

Autoregressive modeller for tekst

I denne delen fokuserer vi på autoregressive språkmodeller, som genererer tekst ett token om gangen, betinget på tidligere genererte tokens.

Generering tekst ett ord om gangen

Startsetning (prompt): "Hva er en eksamen?"
Start på svar: "En eksamen ..."

Nå må dere fullføre setningen. Dere tar tur på å si det neste ordet dere synes passer bra i setningen.

Diskusjon (~5 min):

1) Hva skjer når noen velger et uventet ord?
2) På hvilke måter ligner dette på hvordan en språkmodell genererer tekst? På hvilke måter er det annerledes?

Autoregressive modeller for tekst

Begrenset kontekstgenerering: Gjenta øvelsen i grupper (5–6 studenter) eller i hele klassen. Bruk samme startsetning og første ord (*Eksamen*).

Ny regel: Denne gangen skal hver person velge det neste ordet basert kun på det siste ordet som ble produsert (dvs. konteksten i denne settingen er begrenset til ett enkelt foregående ord), og ignorere resten av setningen (~5 minutter). Dere kan hviske ordet sitt til den neste personen eller skrive det ned på papir og vise det til den neste personen. Skriv ned den fulle setningen og del den med klassen for diskusjon.

Diskusjon (~10 min):

1) Hvordan skilte de genererte setningene seg fra forrige øvelse?
2) Hva forteller dette oss om kontekstens betydning i språkmodeller?
3) Hvordan "husker" autoregressive språkmodeller kontekst? Hva lærte du om dette i forelesningen?

Generative modeller og kontekst

Fyll inn det manglende ordet

- Dra meg baklengs inn i [MASK]
- Helmaks, [MASK]
- I 1969 landet mennesket på [MASK]
- Alle monner [MASK]
- Hest er best på [MASK]
- Nå kan vi ta det rolig de neste [MASK] år
- Vi har en [MASK] i taket
- Jeg har aldri [MASK] en så fin dag

Fyll inn de manglende ordene individuelt basert på intuisjon og forkunnskaper. Del løsningen deres i gruppen.

Generative modeller og kontekst

Sammenlikn med språkmodeller

I grupper: test de samme setningene med forskjellige språkmodeller. Dere kan dele dere innad i gruppen, og hver person sjekker ut en annen språkmodell. Dere kan velge modellene (for eksempel: ChatGPT, Claude, Gemini, DeepSeek, Grok, osv.) (~5 minutter).

Diskusjon (~10 min):

1) Hvordan kan vi forklare modellens svar? *Er modellen avhengig av vanlige fraser, grammatikk eller faktakunnskap?*
2) Hvilken type kontekst var avgørende? *Var det de foregående ordene, grammatisk struktur, verdenskunnskap eller kulturell (norsk) kontekst?*
3) Hva skjer hvis vi fjerner eller endrer ett ord i setningen? *Endres modellens prediksjon betydelig? Hva forteller dette oss om dens følsomhet for kontekst?*

Grunntrening (Pre-training), Instruksjonsjustering (fine-tuning) og Preferansejustering (alignment)

Diskuter i grupper på 3-4 (~10 min):

1) Hva skjer i fasene: grunntrening , instruksjonsjustering og preferansejustering?
2) Hva er målet med preferansejustering?
3) Hva kan en generativ modell justeres mot? Er det utfordringer med justeringsbegrepet (alignment)? (Hint: hvem bestemmer?)

Scenario: Preferansejustering

Hver gruppe er ansvarlig for justeringsfasen i en generativ modell designet for en av følgende applikasjoner:

- Hjelp til læring
- Helseinformasjon
- Nyhetsoppsummeringer
- Kundesupport-chatbot
- Hjelp med kreativ skriving

Diskuter i grupper (~10 min):

- Hva er modellens mål? Hva skal modellen hjelpe brukere med å oppnå i denne applikasjonen?
- Hva betyr god tilpasning i denne sammenhengen? Hva slags atferd eller resultater er ønskelig?
- Hvilke begrensninger eller restriksjoner bør inkluderes? Finnes det emner, toner eller typer råd som bør begrenses?
- Hvilke potensielle feil er mest alvorlige? Hvilke typer feil kan forårsake skade eller feilinformasjon?

Oppgave: Evaluering av språkmodeller

Reflekter først individuelt (~3 min), og diskuter deretter i grupper (~10 min):

1. Hvilke egenskaper bør en god språkmodell ha?
2. Hvordan ville du testet disse egenskapene?
   Hvilke typer oppgaver eller spørsmål ville du laget?
3. Hvordan kan man måle ytelsen til en språkmodell?
4. Hvilke utfordringer kan oppstå når man evaluerer språkmodeller?
   Er noen egenskaper vanskeligere å måle enn andre?

Gruppene deler det de har diskutert.

Oppgave: Evaluering av språkmodeller

Jobb i de samme gruppene og undersøk hvordan språkmodeller evalueres i praksis ved hjelp av offentlige leaderboards. Hver gruppe velger ett forskjellig leaderboard: Chatbot Arena (LMSYS), LiveBench, eller Vellum.ai.

Diskuter i gruppen (~10 min):

- Hvilke typer oppgaver finner dere?
- Hvordan er oppgavene formulert?
  (flervalg, klassifisering, åpen tekstgenerering)
- Hvordan blir modellene evaluert?

Hver gruppe presenterer kort hva de har funnet.

Oppgave: Sammenligne språkmodeller

Jobb i grupper på 3–4.

Test de samme promptene på minst to ulike språkmodeller (~10 min):

- En lukket modell (f.eks. ChatGPT, Claude, Gemini)
- En åpen modell via GPT UiO: https://gpt.uio.no/chat *(f.eks. Kimi, GLM, Mistral, GPT-OSS)*

Velg prompts å utforske (Bruk samme prompt på alle modellene)

- Forklar et begrep
- Oppsummer en kort tekst
- Svar på et faktaspørsmål
- Skriv en kort historie

Oppgave: Sammenligne språkmodeller

Sammenlign svarene fra modellene og diskuter (~10 min):

- Hvordan skiller svarene seg i stil, detaljnivå og klarhet?
- Hvilken modell presterte best?
- Har modellene ulike svakheter eller begrensninger?
- Kan vi alltid stole på svarene fra modellene?

Hver gruppe presenterer kort hva de har funnet.

Evaluering av generative modeller

Scenario: Tenk deg at du har flere generative modeller for **bildegenerering**. Generative modeller kan lære den underliggende fordelingen av bildedata (f.eks. dyreansikter) og generere nye bilder som ligner på treningsdataene. Det er ikke alltid like enkelt å evaluere kvaliteten på slike modeller. I dette scenariet trenes 4 modeller på de samme bildene, men produserer forskjellige resultater.

Treningsdata

I grupper (~10 min):

- Diskuter og bestem hvilket generert datasett som er best totalt sett
- Forklar tydelig hvorfor dere mener det er best
- Identifiser og beskriv svakheter i de andre datasettene

Tips: Noen vanlige problemer å vurdere

- Svært lav bildekvalitet eller urealistiske resultater
- Memorering av treningsdata (mangel på originalitet)
- Mangel på diversitet (f.eks. manglende visse typer dyreansikter, også kjent som moduskollaps)
- God balanse mellom realisme og diversitet

Treningsdata

Generert 1

Generert 2

Generert 3

Generert 4

I grupper (~10 min):

- Diskuter og bestem hvilket generert datasett som er best totalt sett
- Forklar tydelig hvorfor du mener det er best
- Identifiser og beskriv svakheter i de andre datasettene

Tips: Noen vanlige problemer å vurdere

- Svært lav bildekvalitet eller urealistiske resultater
- Memorering av treningsdata (mangel på originalitet)
- Mangel på diversitet (f.eks. manglende visse typer dyreansikter, også kjent som moduskollaps)
- God balanse mellom realisme og diversitet

Treningsdata

Moduskollaps

Memorering

Dårlig kvalitet

God

Diskusjon: Evaluering av generative modeller

Diskuter i grupper (~8 min):

1) Hvilke egenskaper forventer dere av en god generativ modell (f.eks. tekst eller bilde-modeller)?

2) Er det vanskeligere å evaluere generative modeller sammenlignet med tradisjonelle prediktive modeller? Hvorfor/Hvorfor ikke?