Uke 12: Filosofi og Framtid

1 Turing-testen i dagens kontekst (∼35 minutter)

Alan Turing foreslo i 1950 det han kalte *The Imitation Game*, senere kjent som Turing-testen, i artikkelen *Computing Machinery and Intelligence.*[1] Turing stilte spørsmålet: "Can machines think?"

I stedet for å definere hva det vil si å tenke, foreslo han en praktisk tilnærming: hvis en maskin kan føre en samtale på en slik måte at et menneske ikke kan skille den fra et annet menneske, bør vi da si at maskinen tenker?

Dette var en radikal idé i 1950, som flyttet fokuset fra grunnleggende filosofiske spørsmål som "*har maskiner en sjel*" til observasjon av atferd: "*oppfører maskinen seg som om den tenker?*". I dag kan store språkmodeller føre naturlige samtaler, uttrykke følelser, resonnere (tilsynelatende), og tilpasse seg kontekst.

Består disse modellene i praksis Turing-testen, og betyr det virkelig at de tenker?

Oppgave 1: The Chinese room (∼15 minutter)

"*The Chinese room*" er et tankeeksperiment introdusert av John Searle (1980)[2] for å stille spørsmål ved om maskiner virkelig *forstår* språk, eller bare manipulerer symboler i henhold til regler, og dermed *imiterer* forståelse.

I tankeeksperimentet sitter en person som ikke forstår kinesisk i et rom og følger et sett med instruksjoner for å svare på kinesiske tegn. For en utenforstående observatør kan svarene virke meningsfulle, selv om personen ikke forstår språket.

Diskuter i små grupper på 3–4 (∼10 minutter):

[1] https://academic.oup.com/mind/article-abstract/LIX/236/433/986238?redirectedFrom=fulltext&login=false

[2] The Chinese room ble introdusert av John Searle i 1980 i artikkelen "Minds, Brains, and Programs", publisert i tidsskriftet Behavioral and Brain Sciences

- Hva er forskjellen mellom å bruke regler korrekt og å forstå meningen med det man gjør?
- I det kinesiske rommet forstår ikke personen kinesisk, men systemet (person + regler) produserer riktige svar. Mener du at *systemet som helhet* forstår kinesisk? Hvorfor eller hvorfor ikke?
- Hva ville telle som bevis for at noen (eller noe) virkelig forstår et språk?
- Kan et system fremstå som om det forstår noe uten faktisk å gjøre det? Hvordan kunne vi skille mellom disse?
- Tror du at dagens store språkmodeller er mer som personen i rommet, eller noe mer? Hvorfor?

Diskusjonspunktene oppsummeres i plenum (∼5 minutter).

Oppgave 2: Sammenlikne svar fra en språkmodell og et menneske (∼20 minutter)

1. Studentene danner grupper på 3–5 personer.
2. Gruppen velger 1–2 spørsmål som de stiller både til en menneskelig deltaker og tre språkmodeller. Eksempler på spørsmål er vist nedenfor, men gruppene står fritt til å finne på egne.

   Eksempler på språkmodeller:

   - UiO-GPT: https://www.uio.no/tjenester/it/ki/gpt-uio/
   - Grok: https://grok.com
   - Claude: https://claude.ai/

   Eksempler på spørsmål:

   - "Hva gjør deg mest stolt?"
   - "Hva gjør deg mest glad?"
   - "Kan du fortelle om en vanskelig beslutning du har tatt?"
   - "Hvordan vet du at du forstår et spørsmål?"
   - "Hva føler du når noen kritiserer deg?"
3. Gruppen skriver først ned svarene fra "**mennesket**" på spørsmålene. Svarene bør være på 1–2 setninger.

4. Deretter stiller de de samme spørsmålene til minst to språkmodeller og samler inn svarene. Svarene skal igjen være på 1–2 setninger (sørg for å spesifisere dette i prompten til språkmodellen).

5. Diskuter sammen i gruppen:

   - Hvilke svar virket mest menneskelige, og hvorfor?
   - Viste noen av modellene tegn til forståelse, refleksjon eller selvbevissthet?
   - Var det noen svar som tydelig avslørte at det var en maskin?

Gjette menneske eller maskin?

1. Studentene skriver ned svarene fra modellene og mennesket uten å avsløre kildene.

2. Par av grupper bytter svar og fungerer som dommere, og forsøker å gjette hvilke svar som kommer fra et menneske. De diskuterer:

   - Hvilke svar virker mest menneskelige, og hvorfor?

3. Gruppene avslører de riktige svarene.

4. Oppsummering i plenum:

   - Klarte dere å gjette riktig? Hvilke modeller lurte dere?
   - Hva lærte dere om modellene ved å stille egne spørsmål?
   - Kan evnen til å gi meningsfulle svar tolkes som et tegn på forståelse? Hva kan vi si om en modell som består testen? Kan den tenke?
   - Kan en maskin være intelligent uten å bestå testen? Hvorfor/hvorfor ikke?
   - Er Turing-testen fortsatt et gyldig/godt mål på intelligens i 2026?

2 Kunstig intelligens i sjakk (∼25 minutter)

Brettspill, og særlig sjakk, har vært på AI-agendaen helt siden begynnelsen og de første sjakkspillende dataprogrammene ble utviklet rundt 1950. John McCarthy (en av AI-feltets grunnleggere) beskrev sjakk som "kunstig intelligensens bananflue", med henvisning til hvordan fruktfluen (Drosophila) brukes som modellorganisme i genetisk forskning.

I mange år ble sjakk betraktet som en kjerneegenskap ved menneskelig intelligens og et område der man antok at maskiner aldri ville oppnå menneskelig nivå. Dette inkluderte selv verdensmesteren Garry Kasparov. Men i 1997 tapte han mot IBMs

Deep Blue, en superdatamaskin som på den tiden representerte den mest avanserte maskinvaren som fantes. (Kasparov bestridte riktignok resultatet.) For mange var ikke Deep Blues seier nok til å bevise ekte kunstig intelligens.

John McCarthy uttalte rundt 1990: "Chess programs now play at grandmaster level, but they do it with limited intellectual mechanisms compared to those used by a human chess player, substituting large amounts of computation for understanding. Once we understand these mechanisms better, we can build human-level chess programs that do far less computation than do present programs."[3]

Siden den gang har sjakkprogrammene blitt enda sterkere. Særlig AlphaZero, som lærte å spille sjakk gjennom forsterkende læring (reinforcement learning) ved å spille mot seg selv.

Da Magnus Carlsen ble spurt om han trodde han kunne slå AlphaZero, svarte han smilende: ”Nei.” AlphaZero har også introdusert nye og kreative trekk som mennesker ikke tidligere hadde brukt og Carlsen har begynt å bruke flere av dem i sitt eget spill.

Oppgave 1: Diskusjon (∼15 minutter)

Arbeid i små grupper (3–4). Bruk gjerne de samme gruppene som i forrige oppgave. Diskuter følgende spørsmål:

- Hvor representativ og relevant er sjakk som test for kunstig intelligens?
- Hvilke aspekter ved intelligens demonstrerer sjakkprogrammer, og hvilke gjør de ikke?
- Hvordan vurderer dere McCarthys syn om at tradisjonelle sjakkprogrammer ikke utviser menneskelig intelligens, men i stedet erstatter forståelse med beregning?
- Hva betyr det egentlig å “forstå” (slik McCarthy bruker begrepet)?
- Hva er forholdet mellom det å tenke, det å forstå og det å være intelligent?
- Er AlphaZero kreativ? Hvis ja, på hvilken måte?
- Når en verdensmester lærer nye ideer fra en datamaskin, hva sier dette om forholdet mellom menneskelig og maskinell intelligens?
- Hvordan skiller AlphaZero seg fra Deep Blue i måten den lærer på (dere kan undersøke dette)? Hva sier dette om læring som et kjennetegn ved intelligens?

[3] https://www.chessprogramming.org/John_McCarthy

- Finnes det andre eksempler på KI i spill der det er spesielt vanskelig å avgjøre om systemet faktisk forstår spillet, eller bare presterer godt?

Diskusjonspunktene oppsummeres i plenum (∼5 minutter).

3 Kan maskinlæringsmodeller være kreative? (∼40 minutter)

Filosofen David Hume hevdet at alle ideer kommer fra erfaring. Ifølge Hume, selv når vi tror vi er kreative, omorganiserer eller kombinerer vi bare tidligere erfaringer. I denne forstand er ingen konsepter virkelig nye.

What never was seen or heard of may still be conceived; nothing is beyond the power of thought except what implies an absolute contradiction. But although our thought seems to be so free, when we look more carefully we'll find that it is really confined within very narrow limits, and that all this creative power of the mind amounts merely to the ability to combine, transpose, enlarge, or shrink the materials that the senses and experience provide us with. When we think of a golden mountain, we only join two consistent ideas—gold and mountain—with which we were already familiar. We can conceive a virtuous horse because our own feelings enable us to conceive virtue, and we can join this with the shape of a horse, which is an animal we know. In short, all the materials of thinking are derived either from our outward senses or from our inward feelings: all that the mind and will do is to mix and combine these materials. David Hume, "On the Origin of Ideas"

Studentene diskuterer i grupper (∼8 minutter):

1. Kan dere komme på noe dere vil kalle en "helt ny idé"?
2. Hvilke deler av denne ideen kommer fra tidligere erfaringer?
3. Er dere enige med Hume i at alle ideer er rekombinasjoner? Hvorfor/hvorfor ikke?

Moderne maskinlæringsmodeller (f.eks. generative modeller) trenes på data.

Studentene diskuterer i grupper (∼10 minutter):

1. En generativ modell lager et nytt bilde. Er det virkelig "nytt"?
2. Gjør en maskinlæringsmodell noe som ligner på Humes idé om det rekombinerende sinnet?

3. Kan en modell generere noe meningsfullt eller nyttig som den aldri direkte har observert før?

4. Er menneskelig fantasi og maskinlæringsmodeller fundamentalt forskjellige eller overraskende like?

Diskusjonspunktene oppsummeres i plenum (∼5 minutter).

Scenario: AlphaFold og vitenskapelig kreativitet

AlphaFold (utviklet av DeepMind)[4] er en maskinlæringsmodell som predikerer den tredimensjonale strukturen til proteiner basert på deres aminosyresekvenser. Proteiner er kjeder av aminosyrer som folder seg til komplekse strukturer, og formen deres bestemmer funksjonen i biologien. Tradisjonelt har det å bestemme proteinstrukturer krevd kostbare og tidkrevende laboratorieeksperimenter. AlphaFold lærer mønstre fra kjente proteinstrukturer og kan beregningsmessig predikere svært nøyaktige nye strukturer.

Scenario: En forsker bruker AlphaFold til å predikere strukturen til et protein som aldri tidligere har blitt observert eksperimentelt. Den predikerte strukturen viser seg å være korrekt og fører til et gjennombrudd innen legemiddelutvikling.

Diskuter i grupper på 3–4 studenter (∼20 minutter):

1. Oppdaget AlphaFold noe nytt, eller utledet det bare fra eksisterende data?

2. Kan det å predikere noe som allerede eksisterer i naturen (men som var ukjent for oss) regnes som kreativitet?

3. Hvem bør få æren for oppdagelsen?

   - Forskerne?
   - Utviklerne av modellen?
   - Modellen selv?

4. Er dette forskjellig fra hvordan mennesker gjør vitenskapelige oppdagelser?

5. AlphaFold "forstår" ikke biologi i menneskelig forstand. Har den sin egen form for "forståelse", og kan vi i så fall dra nytte av at den er forskjellig fra vår? Har forståelse (og formen den kommer i) betydning for kreativitet eller oppdagelse?

[4] https://deepmind.google/science/alphafold/

6. Anta at AlphaFold predikerer en proteinstruktur som ikke er kjent å eksistere i naturen, men som kan syntetiseres og er nyttig. Er dette mer kreativt enn å predikere eksisterende strukturer? Hvorfor eller hvorfor ikke?

7. Utfordrer dette eksempelet ideen om at maskinlæringsmodeller kun rekombinerer tidligere data?

Diskusjonspunktene oppsummeres i plenum (∼5 minutter).

Ekstra (valgfritt):

Moderne forskning bruker modeller inspirert av AlphaFold til å designe helt nye proteiner.

- Er det å designe et nytt protein nærmere kreativitet enn å predikere den korrekte strukturen til et protein som finnes i naturen?
- Hvor bør vi trekke grensen mellom prediksjon og oppfinnelse?