Uke 14: Etikk

1 Etikk i KI-livssyklusen (∼35 minutter)

1.1 Individuell idémyldring (∼3 minutter)

Bruk 3 minutter på å individuelt skrive ned så mange etiske problemstillinger knyttet til KI som du kan komme på. Ikke filtrer eller evaluer ideene dine, bare skriv. Forsøk å være så konkret som mulig.

1.2 Diskusjon i små grupper (∼10 minutter)

Nå skal dere arbeide i små grupper eller par. Sammenlign listene deres i gruppen og diskuter følgende:

- Hvilke problemstillinger dukket opp gjentatte ganger i gruppen?
- Hvilke problemstillinger var uventede eller overraskende for andre i gruppen?

1.3 Gruppering i modellens livssyklus (∼10 minutter)

Sorter nå problemstillingene inn i de tre fasene av modellens livssyklus: data, trening og applikasjon. Hvis en bestemt etisk bekymring passer til flere faser, prøv å dele den opp og gjøre den mer konkret.

1.4 Plenumsdiskusjon med lærer (∼10 minutter)

Gruppene deler sine kategoriserte lister. Læreren kan også introdusere noen oversette problemstillinger.

Reflekter over følgende sammen i klassen:

- Overrasket noen av problemstillingene, foreslått av andre grupper eller læreren, deg?
- Er noen faser mer etisk ladet enn andre?

2 Transparens og dokumentasjon (∼35 minutter)

Elevene fortsetter i par eller små grupper. Et av de etiske ansvarsområdene til modellutviklere er modelltransparens, der dokumentasjon er et sentralt element. Diskuter følgende spørsmål (∼10 minutter):

- **Hva betyr transparens i sammenheng med en ML-modell?**
- **Hvorfor er transparens viktig, hvem har nytte av det, og hva kan skje hvis det mangler?**
- **Hva vil det si å dokumentere en modell, og hvilken form kan dokumentasjon ha? Hvordan bidrar dokumentasjon til å oppnå transparens i praksis?**
- **Hvis du var modellutvikler, hvilken informasjon ville du anse som viktig å dokumentere og gjøre offentlig tilgjengelig om modellen din?**

Resultatene av diskusjonene deles med klassen (∼5 minutter). Nå er det tid for å utforske modellkort på Hugging Face (∼15 minutter). Gå til Gemma 2-modellkortet (Google, 2024) på https://huggingface.co/google/gemma-2-2b og les modellkortet:

- Synes du modellen er godt dokumentert? Hvorfor / hvorfor ikke?
- Mangler det noe du ville ha villet vite før du tok i bruk denne modellen?
- Var det noe inkludert informasjon som overrasket deg?

Gå nå til Mistral 7B-modellkortet (Mistral AI, 2023) på https://huggingface.co/mistralai/Mistral-7B-v0.1 og sammenlign det med Gemma 2:

- Hva er de viktigste forskjellene mellom de to kortene?
- Hvem tror du faktisk leser disse kortene i praksis?

Resultatene av diskusjonene deles med klassen (∼5 minutter).

3 Skjevhet (bias) i maskinlæring (∼50 minutter)

3.1 Diskusjon (∼ 15min)

Studentene arbeider i par eller små grupper og diskuterer spørsmålene nedenfor (∼ 10min). Dere oppfordres til først å reflektere på egen hånd i et par minutter.

1. **Alle systemer, både datadrevne og menneskelige, kan ha skjevhet (bias). Hva gjør skjevhet særlig utfordrende og problematisk i kunstig intelligens og maskinlæring?**
2. **Diskuter hvor og hvordan skjevhet kan oppstå under utviklingen av en maskinlæringsmodell (for eksempel: datainnsamling, merking, valg av variabler, evaluering, applikasjon).**
3. **Gi eksempler på to eller flere virkelige maskinlæringssystemer som har vist eller kan vise skjevhet. Forklar kort hvordan skjevheten har oppstått eller oppstår i disse.**
4. **Er det mulig at skjevhet i en modell kan være rettferdig eller ønskelig? Forklar hvorfor, og illustrer med et eksempel.**

Resultatene fra diskusjonene deles med klassen (∼5 minutter).

3.2 Case-studie I: Kjønnsskjevhet i maskinoversettelse (∼15 minutter)

Se på følgende utdata fra Google Translate, ved oversettelse fra estisk – et språk uten grammatisk kjønn – til engelsk:

Estisk (kjønnsnøytralt)	**Engelsk (Google Translate)**
Ta on ilus.	She is beautiful.
Ta on tark.	He is smart.
Ta on tugev.	He is strong.
Ta on president.	He is the president.
Ta on arst.	He is a doctor.
Ta on koristaja.	She is a cleaner.
Ta on juuksur.	She is a hairdresser.
Ta on õpetaja.	She is a teacher.
Ta on insener.	He is an engineer.
Tema otsustab.	He decides.

På estisk er *ta* og *tema* kjønnsnøytrale pronomen. Arbeid gjennom følgende spørsmål i gruppen din (∼10 minutter):

1. **Hvilket mønster legger du merke til i måten Google Translate tilordner kjønn på? Hva avslører dette om treningsdataene?**
2. **På hvilket stadium av ML-pipelinen oppsto denne skjevheten sannsynligvis (datainnsamling, merking, trening, applikasjon, eller andre steder)?**
3. **Prøv nå de samme estiske setningene i et par LLM-er (f.eks. ChatGPT, Claude, Gemini, Grok, Mistral). Håndterer de kjønn ulikt? I så fall, hvorfor kan det være? "Ta on ilus. Ta on tore. Ta on tark. Ta on tugev. Ta on president. Ta on arst. Ta on koristaja. Ta on juuksur. Ta on õpetaja. Ta on insener. Tema otsustab"**
4. **Gjenta oversettelsen i de samme LLM-ene i en ny økt. Denne gangen, start med de stereotypisk mannlig-kodede setningene først: "Ta on insener. Ta on president. Ta on arst. Ta on tugev. Ta on tark. Tema otsustab. Ta on õpetaja. Ta on juuksur. Ta on koristaja. Ta on tore. Ta on ilus." Endret oversettelsene seg? I så fall, hva sier det deg om LLM-ens sensitivitet for rekkefølgen i konteksten?**

Resultatene fra diskusjonene deles med klassen (∼5 minutter).

3.3 Case-studie II: Skjevhet i en maskert språkmodell (∼20 minutter)

BERT (Bidirectional Encoder Representations from Transformers) er en maskert språkmodell: gitt en setning med et manglende ord, forutsier den de mest sannsynlige kandidatene til å fylle tomrommet. Dette gjør den til et nyttig verktøy for å undersøke hvilke assosiasjoner en modell har lært fra treningsdataene sine.

Gå til `https://huggingface.co/google-bert/bert-base-uncased` og bruk inferenswidgeten. Kopier og lim inn hver setning nedenfor direkte i tekstboksen. Modellen vil automatisk oppdage token-et `[MASK]` og forutsi de mest sannsynlige ordene for å fylle det, sammen med en sannsynlighet for hvert forslag som indikerer hvor sikkert modellen forbinder det ordet med den gitte konteksten. Arbeid i par eller smågrupper, og følg oppgavene/spørsmålene nedenfor ($\sim 15min$).

1. **Prøv følgende setninger og noter de øverste prediksjonene for `[MASK]`:**
   - `The doctor finished the rounds. [MASK] was exhausted.`

- `The nurse finished the rounds. [MASK] was exhausted.`
- `The CEO gave [MASK] speech to the board.`
- `My [MASK] is an engineer.`
- `My [MASK] is a nurse.`

2. **Hva forteller sannsynlighetene deg, utover bare den øverste prediksjonen?**
3. **BERT brukes sjelden direkte av sluttbrukere. Hvorfor betyr det likevel noe at BERT viser skjevhet?**
4. **Kan du komme på andre potensielt relevante demografiske egenskaper som kan forårsake skjevhet?**
5. **For hver demografiske egenskap du listet opp, kan du komme på noen setninger du kan bruke til å teste potensiell skjevhet i BERT-modellen? Hvilke resultater fikk du?**

Resultatene fra diskusjonene deles med klassen (∼5 minutter).

4 Preferansejustering (Alignment) (∼35 minutter)

Moderne generative modeller som brukes i KI-systemer, blir ofte «alignet» for å følge bestemte normer, regler og verdier. Dette reiser flere grunnleggende spørsmål:

- Hvem har rett til å bestemme hvilke verdier en modell skal følge?
- Spiller det en rolle hvem som bestemmer?
- Hvorfor kan vi ikke bare la modellene være åpne og uten begrensninger?

Studentene arbeider i par eller smågrupper og diskuterer spørsmålene nedenfor (∼25 minutter). Dere oppfordres til først å reflektere på egen hånd i et par minutter.

1. **Hvem bør bestemme hvordan en modell oppfører seg? For hver av følgende aktører, finn ett argument for og ett argument mot å gi dem beslutningsmyndighet (staten, brukerne, samfunnet som helhet, utviklerne, forskerne).**
2. **Er det mulig å bygge en virkelig nøytral modell?**

3. **Diskuter følgende påstand: "Vi tillater mennesker å uttrykke farlige eller umoralske ideer. Hvorfor skal KI holdes til en strengere standard?"**

Resultatene fra diskusjonene deles med klassen (∼10 minutter).

5 Etikk i ulike KI-bruksområder (∼40 minutter)

Studentene deles inn i grupper. Hver gruppe får tildelt ett av scenariene nedenfor. Sammen skal gruppen diskutere og skrive ned sine svar på spørsmålene som følger (∼30 minutter).

5.1 Scenarier

1. **Maskinlæring for jobbsøknader.** Et selskap bruker en ML-modell til automatisk å screene og rangere jobbsøknader før noen menneskelig vurderer ser dem.

2. **Helsevesen og prioritering.** Et sykehus bruker et KI-system til å prioritere hvilke pasienter som skal få behandling først, basert på forutsagte utfall og ressurstilgang.

3. **Kredittvurdering og lån.** En bank bruker en ML-modell til å vurdere kredittverdighet og avgjøre om lånesøknader skal godkjennes.

4. **Tekst-, bilde- og videogenerering i nyheter.** En nyhetsorganisasjon bruker generativ KI til å bistå i produksjon av artikler, bilder og videoinnhold for publisering.

5. **KI i utdanning: personalisert læring.** En skole tar i bruk et KI-system som tilpasser læringsmateriell og tempo til hver enkelt elev basert på elevens prestasjonsdata.

5.2 Spørsmål

For det tildelte scenariet, diskuter og skriv ned gruppens svar på følgende spørsmål. Vær så konkrete som mulig og bruk eksempler der dere kan.

1. **Identifiser de etiske utfordringene knyttet til denne anvendelsen og dens domene.**

2. **Hvem er ansvarlig hvis noe går galt?**
3. **Hvilke grupper kan være underrepresentert eller bli skadelidende av dette systemet?**
4. **Hvordan kan de identifiserte utfordringene adresseres?**
5. **Hvem tjener på, og hvem taper på dette systemet?**

5.3 Plenumsoppsummering

Hver gruppe presenterer sine svar for klassen ($\sim 10min$).

6 Etikk og utforming av KI-framtiden (∼25 minutter)

Studentene arbeider i små grupper og diskuterer de bredere samfunnsmessige implikasjonene av KI på tvers av tre områder: regulering, arbeidsmarkedet og miljøet.

For å styre refleksjonen, diskuter følgende spørsmål (∼15 minutter):

- **Regulering**: Kan du tenke deg områder der det trengs regler og reguleringer for KI? Hvem bør styre KI (nasjonale regjeringer, internasjonale organisasjoner, selskaper)? Kjenner du til noen eksisterende initiativer/institusjoner?
- **Arbeidsmarked**: Hvordan kan KI endre arbeidsmarkedet? Hvilke nye typer jobber kan oppstå, og hvilke kan forsvinne? Hvordan kan samfunnet sikre at verdien KI skaper blir fordelt rettferdig?
- **Miljø**: KI-systemer kan ha svært høyt energiforbruk. Er det likevel mulig at KI kan ha en netto positiv effekt på miljøet? I så fall, hvordan?
- Går disse tre områdene (regulering, arbeidsmarked, miljø) alltid bra sammen? Hvis ikke, hvilke konflikter kan oppstå? For eksempel:
  - Kan strengere regulering bremse innovasjon eller jobbskaping?
  - Kan de økonomiske fordelene ved KI komme på bekostning av miljøet?
  - Kan miljøvennlig KI begrense tilgjengelighet eller øke ulikhet?

Diskusjonene deles med klassen (∼10 minutter).